集合Set

集合，简称集。由任意个元素构成的集体。高级语言都实现了这个非常重要的数据结构类型。

Python中，它是**可变的、无序的、不重复**的元素的集合。

初始化

- set() -> new empty set object
- set(iterable) -> new set object

```
s1 = set()
s2 = set(range(5))
s3 = set([1, 2, 3])
s4 = set('abcdabcd')

s5 = {} # 这是什么？
s6 = {1, 2, 3}
s7 = {1, (1,)}
s8 = {1, (1,), [1]} # ？
```

元素性质

- 去重：在集合中，所有元素必须相异
- 无序：因为无序，所以**不可索引**
- 可哈希：Python集合中的元素必须可以hash，即元素都可以使用内建函数hash
  - 目前学过不可hash的类型有：list、set、bytearray
- 可迭代：set中虽然元素不一样，但元素都可以迭代出来

增加

- add(elem)
  - 增加一个元素到set中
  - 如果元素存在，什么都不做
- update(*others)
  - 合并其他元素到set集合中来
  - 参数others必须是可迭代对象
  - 就地修改

```
s = set()
s.add(1)
s.update((1,2,3), [2,3,4])
```

删除

- remove(elem)
  - 从set中移除一个元素
  - 元素不存在，抛出KeyError异常。为什么是KeyError?
- discard(elem)

    - 从set中移除一个元素
    - 元素不存在，什么都不做
- pop() -> item
    - 移除并返回任意的元素。为什么是任意元素?
    - 空集返回KeyError异常
- clear()
    - 移除所有元素

```
s = set(range(10))
s.remove(0)
#s.remove(11) # KeyError为什么
s.discard(11)
s.pop()
s.clear()
```

修改

集合类型没有修改。因为元素唯一。如果元素能够加入到集合中，说明它和别的元素不一样。

所谓修改，其实就是把当前元素改成一个完全不同的元素，就是删除加入新元素。

索引

非线性结构，不可索引。

遍历

只要是容器，都可以遍历元素。但是效率都是O(n)

成员运算符in

```
print(10 in [1, 2, 3])
print(10 in {1, 2, 3})
```

上面2句代码，分别在列表和集合中搜索元素。如果列表和集合的元素都有100万个，谁的效率高?

IPython魔术方法

IPython内置的特殊方法，使用%百分号开头的

- % 开头是line magic
- %% 开头是 cell magic，notebook的cell

```
%timeit statement
-n 一个循环loop执行语句多少次
-r 循环执行多少次loop，取最好的结果

%%timeit setup_code
  * code.....
```

```
# 下面写一行，列表每次都要创建，这样写不好
%timeit (-1 in list(range(100)))

# 下面写在一个cell中，写在setup中，列表创建一次
%%timeit l=list(range(1000000))
-1 in l
```

set和线性结构比较

```
%%timeit lst1=list(range(100))
a = -1 in lst1
```

```
1.22 µs ± 4.67 ns per loop (mean ± std. dev. of 7 runs, 1000000 loops each)
```

```
%%timeit lst1=list(range(1000000))
a = -1 in lst1
```

```
12 ms ± 116 µs per loop (mean ± std. dev. of 7 runs, 100 loops each)
```

```
%%timeit set1=set(range(100))
a = -1 in set1
```

```
32 ns ± 0.141 ns per loop (mean ± std. dev. of 7 runs, 10000000 loops each)
```

```
%%timeit set1=set(range(1000000))
a = -1 in set1
```

```
32.3 ns ± 0.0916 ns per loop (mean ± std. dev. of 7 runs, 10000000 loops each)
```

结果说明，集合性能很好。为什么?

- 线性数据结构，搜索元素的时间复杂度是O(n)，即随着数据规模增加耗时增大
- set、dict使用hash表实现，内部使用hash值作为key，时间复杂度为O(1)，查询时间和数据规模无关，不会随着数据规模增大而搜索性能下降。

可哈希

- 数值型int、float、complex
- 布尔型True、False
- 字符串string、bytes
- tuple
- None
- 以上都是不可变类型，称为可哈希类型，hashable

set元素必须是可hash的。

集合概念

- 全集
  - 所有元素的集合。例如实数集，所有实数组成的集合就是全集
- 子集subset和超集superset
  - 一个集合A所有元素都在另一个集合B内，A是B的子集，B是A的超集

- 真子集和真超集
  - A是B的子集，且A不等于B，A就是B的真子集，B是A的真超集
- 并集：多个集合合并的结果
- 交集：多个集合的公共部分
- 差集：集合中除去和其他集合公共部分

并集

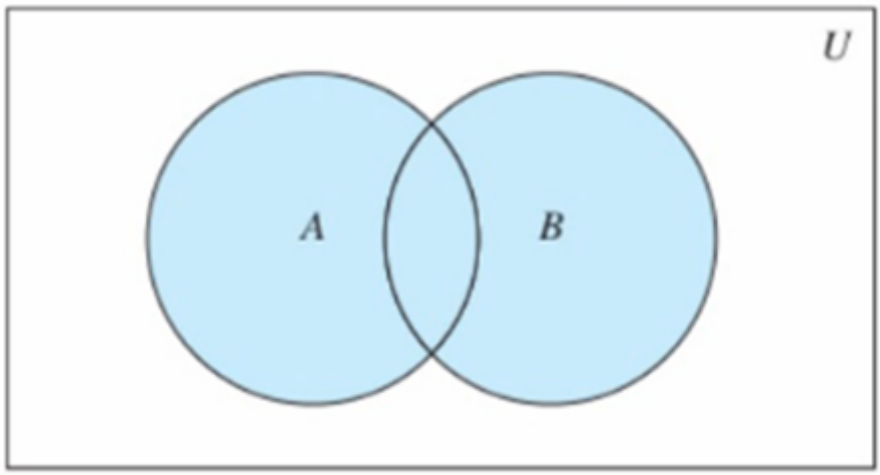

将两个集合A和B的所有的元素合并到一起，组成的集合称作集合A与集合B的并集

- `union(*others)` 返回和多个集合合并后的新的集合
- `|` 运算符重载，等同union
- `update(*others)` 和多个集合合并，就地修改
- `|=` 等同update

交集

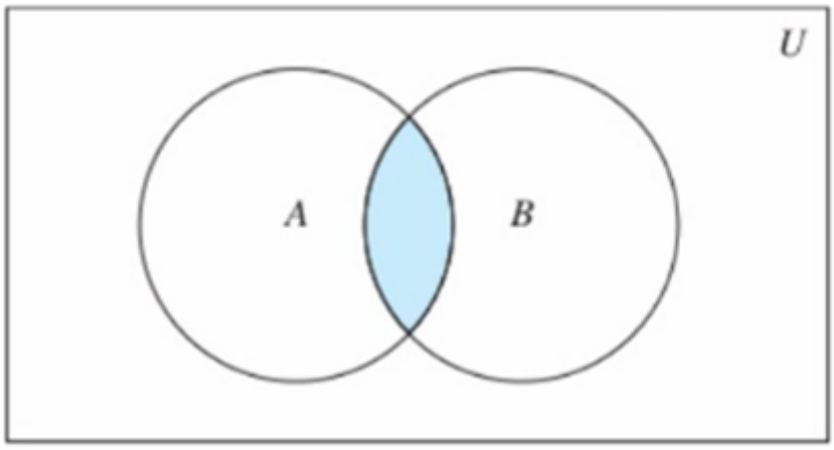

集合A和B，由所有属于A且属于B的元素组成的集合

- `intersection(*others)` 返回和多个集合的交集
- `&` 等同intersection
- `intersection_update(*others)` 获取和多个集合的交集，并就地修改
- `&=` 等同intersection_update

差集

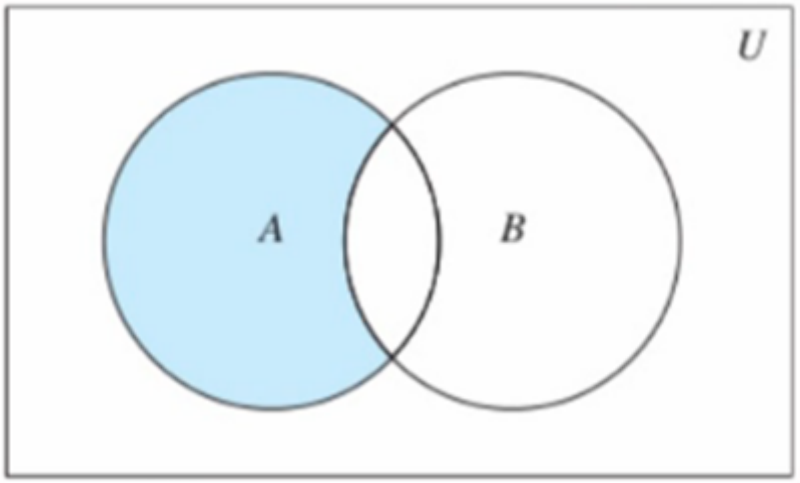

集合A和B，由所有属于A且不属于B的元素组成的集合

- `difference(*others)` 返回和多个集合的差集
- `-` 等同difference
- `difference_update(*others)` 获取和多个集合的差集并就地修改
- `-=` 等同difference_update

对称差集

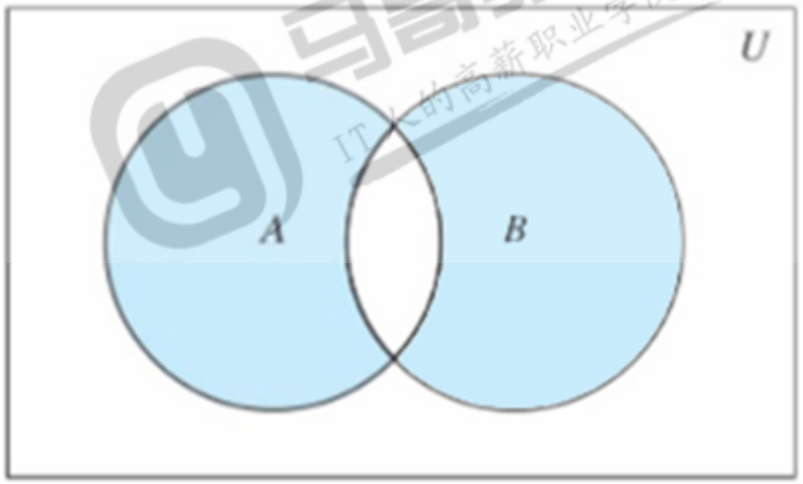

集合A和B，由所有不属于A和B的交集元素组成的集合，记作（A-B）∪（B-A）

- `symmetric_differece(other)` 返回和另一个集合的对称差集
- `^` 等同symmetric_differece
- `symmetric_differece_update(other)` 获取和另一个集合的对称差集并就地修改
- `^=` 等同symmetric_differece_update

其它集合运算

- `issubset(other)、<=` 判断当前集合是否是另一个集合的子集
- `set1 < set2` 判断set1是否是set2的真子集
- `issuperset(other)、>=` 判断当前集合是否是other的超集
- `set1 > set2` 判断set1是否是set2的真超集
- `isdisjoint(other)` 当前集合和另一个集合没有交集，没有交集，返回True

练习：

- 一个总任务列表，存储所有任务。一个已完成的任务列表。找出为未完成的任务

```
业务中，任务ID一般不可以重复
所有任务ID放到一个set中，假设为ALL
所有已完成的任务ID放到一个set中，假设为COMPLETED，它是ALL的子集
ALL - COMPLETED => UNCOMPLETED
```

集合运算，用好了妙用无穷。

字典Dict

Dict即Dictionary，也称为mapping。

Python中，字典由任意个元素构成的集合，每一个元素称为Item，也称为Entry。这个Item是由(key, value)组成的二元组。

字典是**可变的、无序的、key不重复**的key-value**键值对**集合。

初始化

- `dict(**kwargs)` 使用name=value对初始化一个字典
- `dict(iterable, **kwarg)` 使用可迭代对象和name=value对构造字典，不过可迭代对象的元素必须是一个二元结构**
- `dict(mapping, **kwarg)` 使用一个字典构建另一个字典

字典的初始化方法都非常常用，都需要会用

```
d1 = {}
d2 = dict()
d3 = dict(a=100, b=200)
d4 = dict(d3) # 构造另外一个字典
d5 = dict(d4, a=300, c=400)
d6 = dict([('a', 100), ['b', 200], (1, 'abc')], b=300, c=400)
```

```
# 类方法dict.fromkeys(iterable, value)
d = dict.fromkeys(range(5))
d = dict.fromkeys(range(5), 0)
```

元素访问

- d[key]
  - 返回key对应的值value
  - key不存在抛出KeyError异常
- get(key[, default])
  - 返回key对应的值value
  - key不存在返回缺省值，如果没有设置缺省值就返回None
- setdefault(key[, default])
  - 返回key对应的值value
  - key不存在，添加kv对，value设置为default，并返回default，如果default没有设置，缺省为None

新增和修改

- d[key] = value
  - 将key对应的值修改为value
  - key不存在添加新的kv对
- update([other]) -> None
  - 使用另一个字典的kv对更新本字典
  - key不存在，就添加
  - key存在，覆盖已经存在的key对应的值
  - 就地修改

```
d = {}
d['a'] = 1
d.update(red=1)
d.update(['red', 2])
d.update({'red':3})
```

删除

- pop(key[, default])
  - key存在，移除它，并返回它的value
  - key不存在，返回给定的default
  - default未设置，key不存在则抛出KeyError异常
- popitem()
  - 移除并返回一个任意的键值对
  - 字典为empty，抛出KeyError异常
- clear()
  - 清空字典

遍历

1、遍历Key

```
for k in d:
    print(k)

for k in d.keys():
    print(k)
```

2、遍历Value

```
for v in d.values():
    print(v)

for k in d.keys():
    print(d[k])
    print(d.get(k))
```

3、遍历Item

```python
for item in d.items():
    print(item)
    print(item[0], item[1])

for k,v in d.items():
    print(k, v)

for k,_ in d.items():
    print(k)

for _,v in d.items():
    print(v)
```

Python3中，keys、values、items方法返回一个类似一个生成器的可迭代对象

- Dictionary view对象，可以使用len()、iter()、in操作
- 字典的entry的动态的视图，字典变化，视图将反映出这些变化
- keys返回一个类set对象，也就是可以看做一个set集合。如果values都可以hash，那么items也可以看做是类set对象

Python2中，上面的方法会返回一个新的列表，立即占据新的内存空间。所以Python2建议使用iterkeys、itervalues、iteritems版本，返回一个迭代器，而不是返回一个copy

遍历与删除

```python
# 错误的做法
d = dict(a=1, b=2, c=3)
for k,v in d.items():
    print(d.pop(k))
```

在使用keys、values、items方法遍历的时候，不可以改变字典的size

```python
while len(d):
    print(d.popitem())

while d:
    print(d.popitem())
```

上面的while循环虽然可以移除字典元素，但是很少使用，不如直接clear。

```python
# for 循环正确删除
d = dict(a=1, b=2, c=3)
keys = []
for k,v in d.items():
    keys.append(k)

for k in keys:
    d.pop(k)
```

key

字典的key和set的元素要求一致

- set的元素可以就是看做key，set可以看做dict的简化版
- hashable 可哈希才可以作为key，可以使用hash()测试
- 使用key访问，就如同列表使用index访问一样，时间复杂度都是O(1)，这也是最好的访问元素的方式

```
d = {
    1 : 0,
    2.0 : 3,
    "abc" : None,
    ('hello', 'world', 'python') : "string",
    b'abc' : '135'
}
```

有序性

字典元素是按照key的hash值无序存储的。

但是，有时候我们却需要一个有序的元素顺序，Python 3.6之前，使用OrderedDict类可以做到，3.6开始dict自身支持。到底Python对一个无序数据结构记录了什么顺序?

```
# 3.5如下
C:\Python\Python353>python
Python 3.5.3 (v3.5.3:1880cb95a742, Jan 16 2017, 16:02:32) [MSC v.1900 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license" for more information.
>>> d = {'a':300, 'b':200, 'c':100, 'd':50}
>>> d
{'c': 100, 'a': 300, 'b': 200, 'd': 50}
>>> d
{'c': 100, 'a': 300, 'b': 200, 'd': 50}
>>> list(d.keys())
['c', 'a', 'b', 'd']
>>> exit()

C:\Python\Python353>python
Python 3.5.3 (v3.5.3:1880cb95a742, Jan 16 2017, 16:02:32) [MSC v.1900 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license" for more information.
>>> d = {'a':300, 'b':200, 'c':100, 'd':50}
>>> d
{'b': 200, 'c': 100, 'd': 50, 'a': 300}
```

Python 3.6之前，在不同的机器上，甚至同一个程序分别运行2次，都不能确定不同的key的先后顺序。

```
# 3.6+表现如下
C:\Python\python366>python
Python 3.6.6 (v3.6.6:4cf1f54eb7, Jun 27 2018, 03:37:03) [MSC v.1900 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license" for more information.
>>> d = {'c': 100, 'a': 300, 'b': 200, 'd': 50}
>>> d
{'c': 100, 'a': 300, 'b': 200, 'd': 50}
```

```
>>> exit()

C:\Python\python366>python
Python 3.6.6 (v3.6.6:4cf1f54eb7, Jun 27 2018, 03:37:03) [MSC v.1900 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license" for more information.
>>> d = {'c': 100, 'a': 300, 'b': 200, 'd': 50}
>>> d
{'c': 100, 'a': 300, 'b': 200, 'd': 50}
>>> d.keys()
dict_keys(['c', 'a', 'b', 'd'])
```

Python 3.6+，记录了字典key的**录入顺序**，遍历的时候，就是按照这个顺序。

如果使用`d = {'a':300, 'b':200, 'c':100, 'd':50}`，就会造成以为字典按照key排序的错觉。

目前，建议不要3.6提供的这种字典特性，还是以为字典返回的是无序的，可以在Python不同版本中考虑使用OrderedDict类来保证这种录入序。